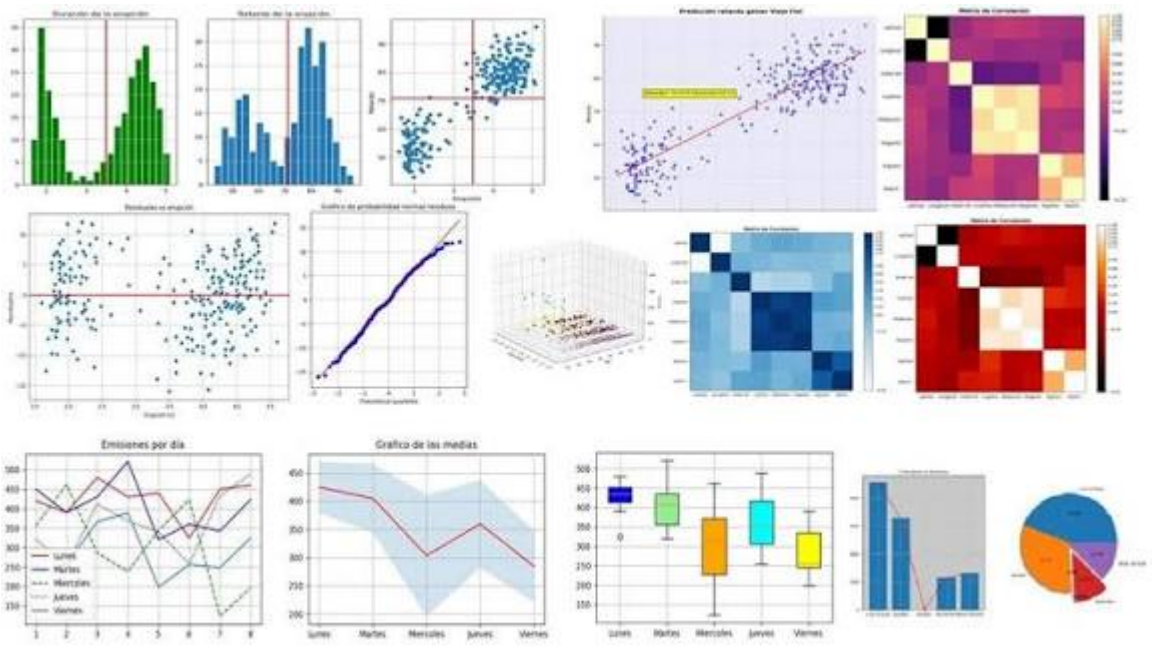
Fundamentos de la Ciencia de Datos - 2026

Trabajo Práctico Especial



<u>Grupo 20</u>

Bisogni, Valentina

Bonanna, Facundo

Juárez, Ariana Martina

<u>Profesor</u>

Deangeli, Duilio

Introducción: 3
Metodología de trabajo: 3
Primer paso: análisis exploratorio: 4
Segundo paso: Limpieza 9
Tercer paso: planteo de hipótesis propias 15
Hipótesis 1 16
Hipótesis 2 18
Hipótesis 3 20
Cuarto paso: Comprobación de hipótesis dadas 22
Hipótesis 4 23
Hipótesis 5 24
Hipótesis 6 32
Conclusiones generales: 38
Bibliografía y enlaces de interés: 39

Introducción:

En este informe buscamos explorar distintas herramientas proporcionadas por la cátedra de la materia "Fundamentos de la Ciencia de Datos", dictada en la Universidad Nacional del Centro de la Provincia de Buenos Aires, para comprobar o rechazar ciertas hipótesis (tanto propias como proporcionadas) que serán planteadas a lo largo del documento. Haremos esto tomando como base el conjunto de datos "Global Foods" que nos fue asignado y con el seguimiento de nuestro ayudante, Duilio Deangeli. Esto se hace a fin de poder entregar una de las tareas núcleo de la materia, el trabajo práctico especial.

Las suposiciones que queremos corroborar (en base a la población medida) se explicarán en detalle a lo largo del texto, pero, en términos generales, se basan en el nivel de calidad de los alimentos del dataset (si la mayoría de alimentos son de "mala calidad" o no), si el grado de procesamiento de un alimento tiene que ver con su impacto ambiental o con la presencia de ciertos ingredientes/aditivos o con un valor nutricional específico y qué proporción de alimentos del dataset son altos en grasas saturadas. Además, vamos a comprobar si podemos explicar mediante ciertas variables del dataset el comportamiento de la calificación Nutri-score.

Para poder corroborar o refutar nuestras hipótesis, intentaremos emplear la mayor cantidad de recursos posibles para demostrar nuestro entendimiento de la materia y obtener conclusiones contundentes con respecto a las hipótesis que trabajaremos.

Metodología de trabajo:

El informe y repositorio de github los realizamos a lo largo de jornadas de trabajo acordadas entre los integrantes. En éstas se debatía de manera conjunta cada uno de los incisos, a fin de que todas las partes entendiéramos el por qué de las respuestas que dimos. Adicionalmente, asistimos a las clases de consulta proporcionadas por la cátedra cuando se presentaba alguna duda.

Como metodología de trabajo, primero nos dedicamos a hacer un análisis exploratorio de los datos, luego planteamos las hipótesis que queríamos explorar y

por último hicimos una limpieza solamente de las variables que queríamos utilizar. Posteriormente realizamos los tests de hipótesis que consideramos pertinentes y sacamos conclusiones en base a los resultados obtenidos.

Primer paso: análisis exploratorio:

La primera consigna del trabajo nos pedía que hiciéramos un análisis exploratorio inicial de la base, investigando con recursos online el origen de los datos (por recursos online entendimos cualquier foro, sitio o repositorio existente en internet). Además, había que caracterizar los atributos del dataset y describir su comportamiento, distribución, si presentaba outliers y si tenía valores nulos.
Creemos que el dataset pudo haber sido rescatado del sitio 'Kaggle' y, según la descripción de la página, estos datos fueron recolectados de fuentes como el departamento de agricultura de los Estados Unidos (USDA) y Open Food Facts, que es una base de datos de alimentos a nivel global.
En total hay más de 45.000 alimentos de fuentes oficiales.
Lo que tiene de especial este dataset es que incluye clasificación NOVA además de indicadores de alérgenos y un índice de salud personalizado. Cabe destacar que la clasificación NOVA es un sistema que agrupa todos los alimentos en cuatro categorías según la naturaleza, el alcance y el propósito del procesamiento industrial que reciben antes de su consumo.
Según la descripción, es el primer dataset que combina datos estadounidense, métricas europeas e información de alérgenos en un solo lugar.
A continuación, resumimos las variables del dataset en un cuadro comparativo:

Atributo	Descripción	Distribución de valores	Tipo	Outliers	¿Presenta nulos?

product_name	Nombre del producto	Nutella, Coca Cola Original, etc.	Cualitativa nominal	No.	Si (nan)
brands	Marca del producto	Coca-Cola, pepsi, Ferrero, etc	Cualitativa nominal	No.	Si (nan)
categories	Categoría del producto.	bebida, lácteos, snacks, comida de mar, entre otros.	Cualitativa nominal	No.	Si (nan)
ingredients	Ingredientes del producto.	crema, azúcar, banana, etc.	Cualitativa nominal	No.	Si (nan)
nutriscore_grade	Calidad nutricional del producto.	A - E. Siendo el A mejor calidad, y bajando hasta el E de peor calidad.	Cualitativa ordinal	No.	Si (NOT-APPLICABLE, UNKNOWN, nan)

nova_group	Grado de procesamiento industrial	1-4. Siendo 1 menor procesamiento que 4.	Cualitativa ordinal	No.	Si (nan)
ecoscore_grade	Indicador del impacto ambiental que tuvo el producto a lo largo de su ciclo de vida.	A-PLUS - F, con A menor impacto y F mayor impacto.	Cualitativa ordinal	No.	Si (NOT-APPLICABLE, UNKNOWN, nan)
allergens	Indica los ingredientes del producto que son capaces de producir reacciones alérgicas	Leche, banana, nueces, etc.	Cualitativa nominal	No.	Si (nan)
energy_kcal	valor energético de un alimento expresado en kilocalorías.	0-5000	Cuantitativa continua	Si.	Si (nan)
fat_100g	Indica la cantidad de grasas por cada 100 gramos del alimento	0-100	Cuantitativa continua	Si.	Si (nan)
saturated_fat_100g	Indica la cantidad de grasas saturadas por	0-100	Cuantitativa continua	Si.	Si (nan)

	cada 100 gramos del alimento				
carbs_100g	Indica la cantidad de carbohidratos por cada 100 gramos del alimento	0-100	Cuantitativa continua	Si.	Si (nan)
sugars_100g	Indica la cantidad de azúcares por cada 100 gramos del alimento	0-100	Cuantitativa continua	Si.	Si (nan)
fiber_100g	Indica la cantidad de fibra por cada 100 gramos del alimento	0-100	Cuantitativa continua	Si.	Si (nan)
proteins_100g	Indica la cantidad de proteína por cada 100 gramos del alimento	0-100	Cuantitativa continua	Si.	Si (nan)
salt_100g	Indica la cantidad de sal por cada 100 gramos del alimento	0-100	Cuantitativa continua	Si.	Si (nan)
sodium_100g	Indica la cantidad de sodio por cada 100 gramos del alimento	0-100	Cuantitativa continua	Si	Si (nan)

contains_gluten	Indica con true o false si el alimento contiene gluten	TRUE/FALSE	Cualitativa nominal dicotómica	No	No
contains_dairy	Indica con true o false si el alimento contiene lácteos	TRUE/FALSE	Cualitativa nominal dicotómica	No	No
contains_nuts	Indica con true o false si el alimento contiene nueces	TRUE/FALSE	Cualitativa nominal dicotómica	No	No
contains_soy	Indica con true o false si el alimento contiene soja	TRUE/FALSE	Cualitativa nominal dicotómica	No	No
contains_eggs	Indica con true o false si el alimento contiene huevo	TRUE/FALSE	Cualitativa nominal dicotómica	No	No
contains_fish	Indica con true o false si el alimento contiene pescado	TRUE/FALSE	Cualitativa nominal dicotómica	No	No
food_type	Tipo de presentación del alimento. Todos los alimentos del dataset son empaquetados,	Todas las muestras son del tipo: branded/ packaged.	Cualitativa nominal	No	No

Tabla 1: Resumen comparativo de todas las variables del dataset

Particularidades de los datos:

- food_type sólo toma un único valor en todas las muestras, para el análisis posterior se puede eliminar ya que no aporta nada.
- Hay errores en las variables del tipo "*_100g", ya que los valores de todas las muestras deberían encontrarse entre 0 y 100 gramos, pero hay registros donde se tienen valores mayores, lo que no tiene sentido según el significado de la variable. Estos registros pueden ser errores de tipeo o quizá uso de otras unidades de medida.
- No todas las variables presentan nulos de la forma 'nan', las variables ecoscore_grade y nutri_score presentan además nulos de la forma UNKNOWN y NOT-APPLICABLE.
- La variable 'nova_group' si bien toma valores del 1 al 4, es cualitativa ordinal (y no cuantitativa discreta), ya que representa una clasificación en grupos de los productos, y no un valor numérico aislado.
- Las variables salt_100g y sodium_100g tienen correlación lineal 1, entonces representan la misma variable. Eliminaremos sodium_100g.

Segundo paso: Limpieza

El próximo paso era hacer una limpieza de variables y analizar qué estrategia tomar cuando se presentaban nulos en las columnas. Decidimos solamente limpiar los atributos que íbamos a usar posteriormente en las hipótesis, decisión que fue aprobada por nuestro ayudante.

La primera variable que limpiamos es 'Nutriscore'. Nosotros analizamos que la mayoría de valores faltantes se asocian a las categorías UNKNOWN y Not-applicable. 'UNKNOWN' es una variable difícil para determinar la razón de su ausencia, pero en el caso de not-applicable se puede saber que probablemente la ausencia se asocia a la columna de los ingredientes, por lo que decidimos tratar la

relación como missing at random (MAR). Este fue el trato que le dimos a cada faltante específico:

not aplicable: se elimina directamente porque no tiene sentido asignar un valor de nutriscore a un alimento que no fue considerado apto para tenerlo en primer lugar. Por lo general un alimento no va a tener esta clasificación porque es fresco (o no procesado), no requiere por ley tener información nutricional asociada, es un alimento de venta directa o artesanal, o tiene tamaño reducido en términos de empaquetado.

unknown: unknown tiene un significado diferente a non aplicable o a nan porque no infiere que el producto no pueda tener un nutriscore, simplemente que se desconoce cuál tiene o no se le ha asignado uno. Como la cantidad de registros Unknown es pequeña en comparación con el tamaño de la muestra, elegimos imputar por k- vecinos más cercanos.

nan: de manera similar al punto anterior, también elegimos imputar por k-vecinos más cercanos porque la cantidad de datos nan es ínfima en relación al tamaño total de los datos y porque por lo general nan está asociado a errores a la hora de escribir/recolectar datos (por ejemplo, alguien que por error introdujo $ en lugar de A), no a que el alimento no tenga o pueda tener un valor de nutriscore.

La segunda variable que limpiamos fue grasas saturadas, que presentaba un único tipo de dato faltante y valores imposibles. Lo tratamos de la siguiente manera:

Nan: Los valores nulos fueron imputados por KNN. Eliminarlos era una de las opciones, ya que al analizar el dataset parecía ser un caso de Missing Completely at Random (MCAR) y eliminarlo no agregaría un sesgo a la muestra. En nuestra hipótesis multivariada decidimos utilizar ambas

opciones para comparar, mientras que en la hipótesis univariada dada por la cátedra utilizamos KNN.

Valores imposibles: Esta columna presentaba valores inválidos claros, como por ejemplo elementos con 140 gramos de grasas saturadas por cada 100 gramos de alimentos. Los imposibles fueron directamente eliminados ya que no consideramos que su borrado fuese a comprometer la aleatoriedad de la muestra.

Este es el gráfico de grasas saturadas antes de la limpieza:

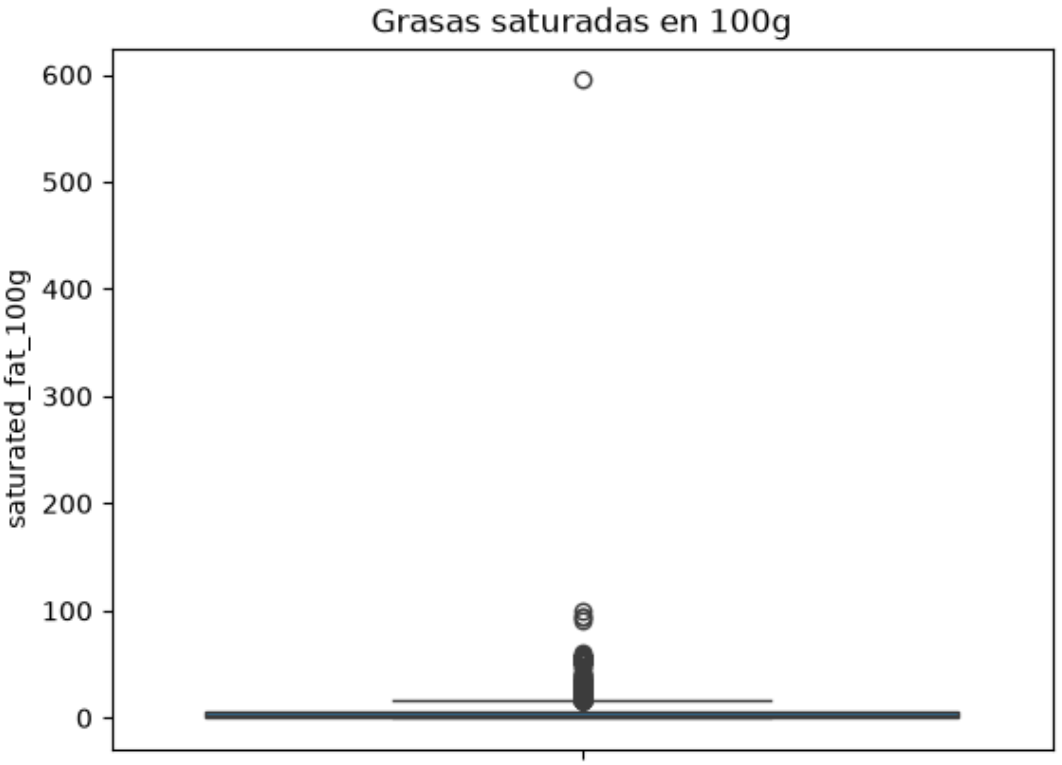


Fig 1: boxplot de la totalidad de valores de la columna relacionada a las grasas saturadas (menos nulos)

y este es el boxplot resultante:

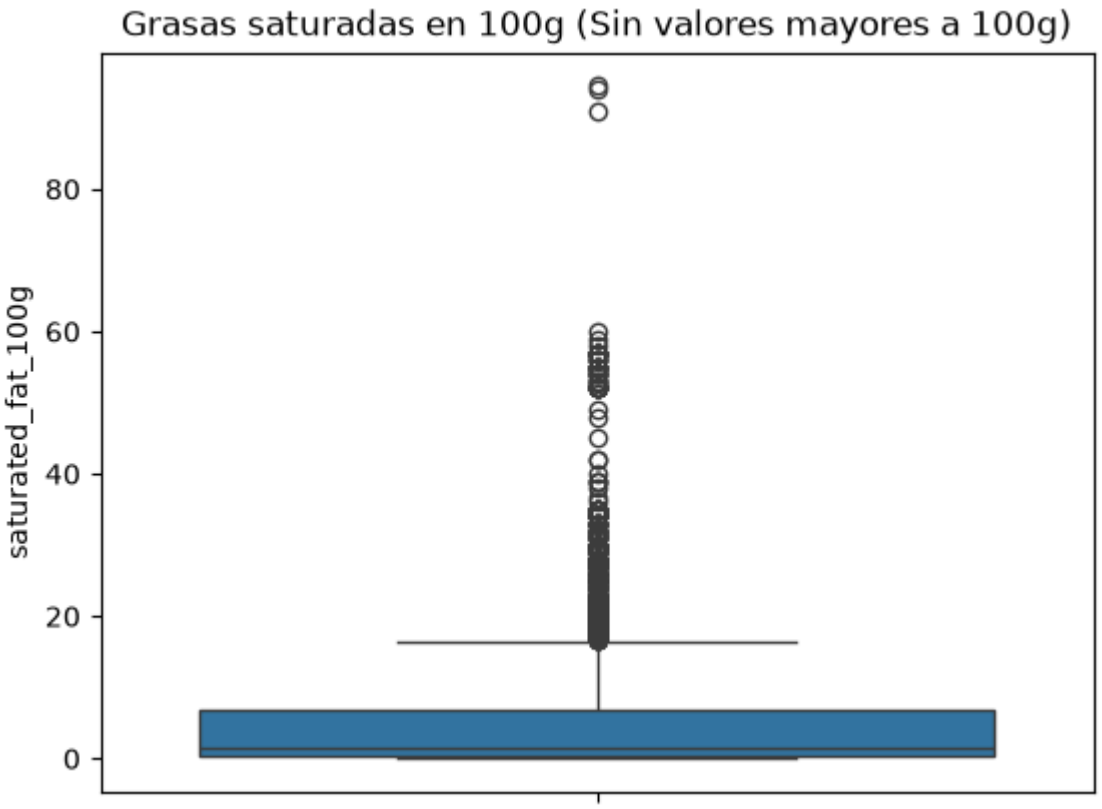


fig 2: boxplot de la totalidad de valores de la columna relacionada a las grasas saturadas (menos nulos y valores imposibles)

La siguiente columna que tuvimos en cuenta para limpiar fue la de ecoscore_grade. Los nulos que existían se presentaban de la forma NAN, UKNOWN y NOT APPLICABLE que, como ya vimos, no significan lo mismo. En este caso vamos a hacer un tratamiento igual al de nutriscore, imputando por 'k' vecinos más cercanos para el caso de unknown y nan, y eliminando las columnas donde no se podía aplicar un grado.

La columna nova_group al ser una variable categórica, debió imputarse por su moda y por 'k' vecinos más cercanos para el posterior análisis de la hipótesis multivariada propuesta por el grupo, proceso que se detalla en el desarrollo de la hipótesis.

La limpieza de la variable "categorías" fue la más compleja, y está explicada en

detalle en la resolución de la hipótesis multivariada dada por la cátedra, al igual que la limpieza de alérgenos.

Parecido al caso de las grasas saturadas en 100g, nuestra próxima limpieza fue de la variable sugars_100g. Si bien hay datos imposibles y datos faltantes, los segundos van a ser tratados a su debido tiempo a la hora de tratar a las variables de manera particular para cada hipótesis.

Valores imposibles: una vez más, algunos valores fueron ingresados de manera incorrecta y marcaban que el alimento tenía una cantidad de azúcar físicamente imposible. Luego de la limpieza, el boxplot que elegimos para representar los datos quedó así:

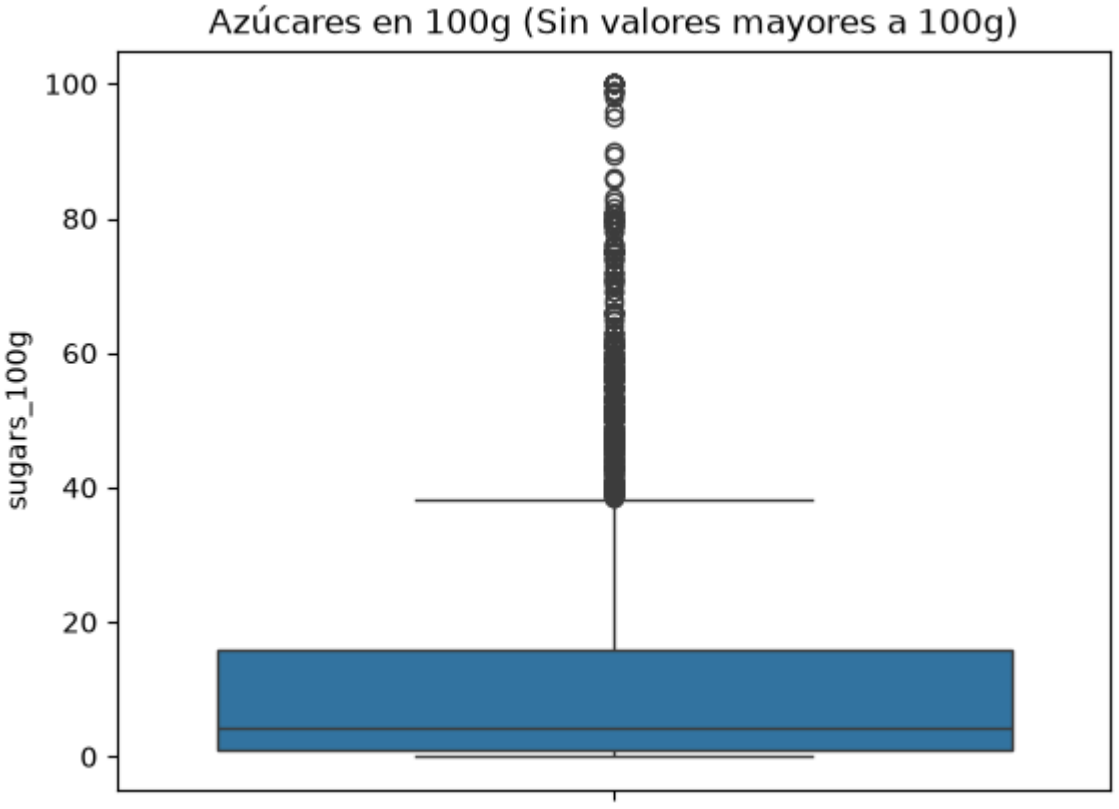


fig 3: boxplot indicando la distribución de los valores de sugars_100g, pero sin la presencia de valores imposibles.

Y, para finalizar, la última variable que trabajamos fue la del valor calórico del alimento. Hay tanto valores faltantes como outliers muy marcados que, asumimos, son valores mal ingresados. Los valores faltantes fueron tratados en el momento de evaluar la hipótesis, pero los valores imposibles fueron tratados en el momento del análisis exploratorio de datos. Cabe destacar que como límite teórico pusimos 900 calorías por cada 100g de producto (dato sacado de internet). La columna no especificaba el peso asociado al valor calórico, pero al hacer una comparación entre los valores más populares de esta columna del dataset y los rotulados de productos reales, los valores se corresponden más al valor calórico en 100 gramos de producto, no a la totalidad.

Boxplot previo a la limpieza:

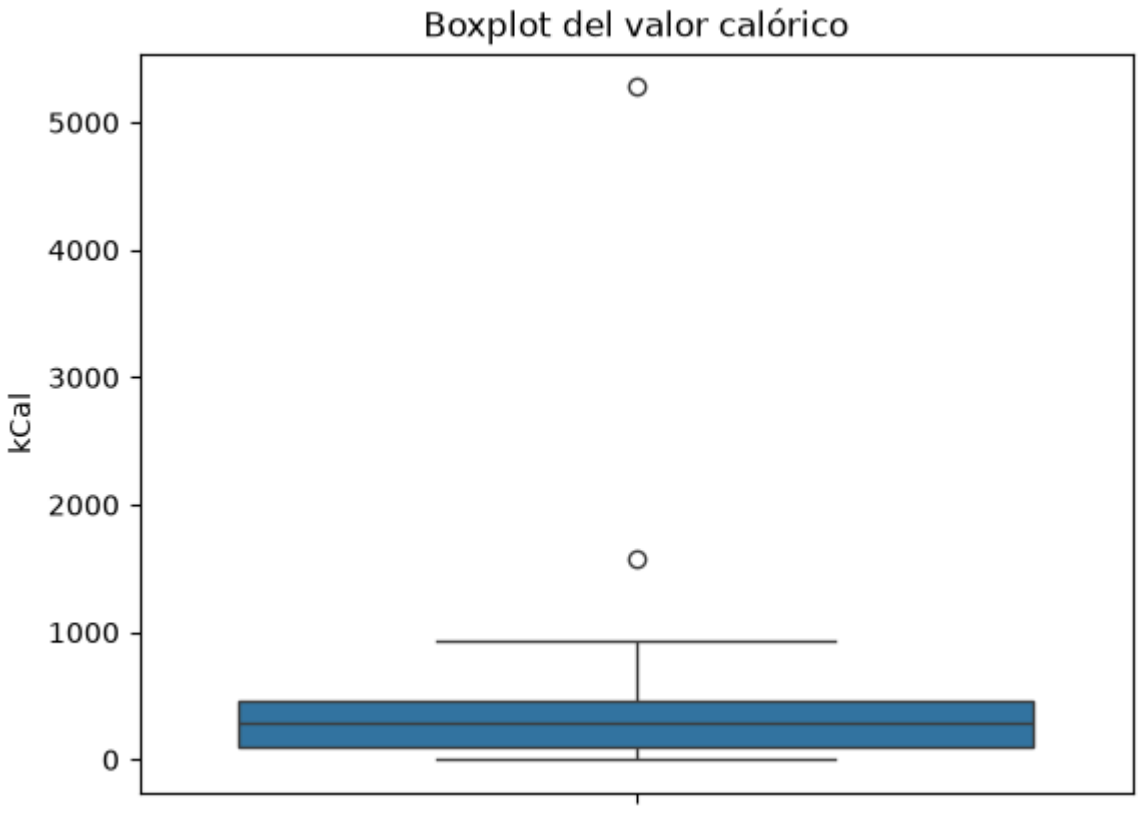


fig 4: boxplot relacionado al valor calórico de las variables junto con los valores imposibles

Boxplot posterior:

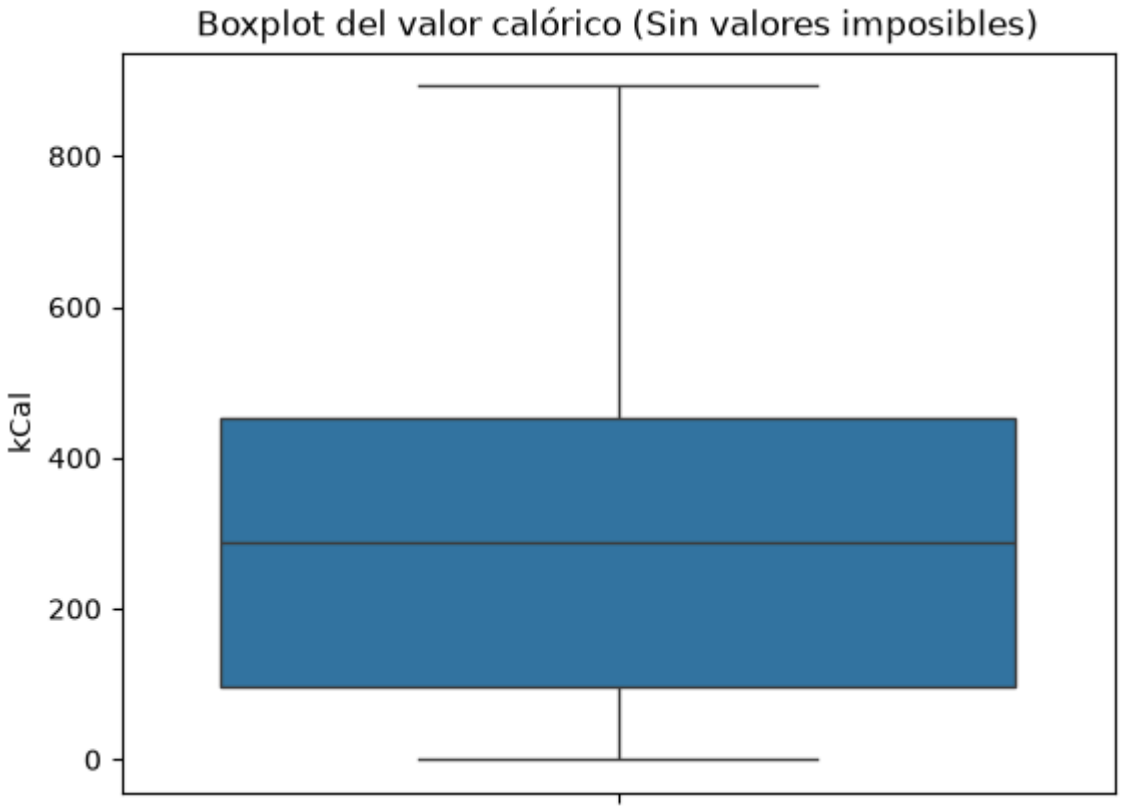


fig 5: este es el boxplot del valor calórico por cada 100g de alimento pero sin tener en cuenta valores imposibles

Tercer paso: planteo de hipótesis propias

Si bien nosotros planteamos primero las hipótesis para saber qué variables teníamos que limpiar, en realidad ese paso correspondía con la consigna número tres. Hicimos tres hipótesis con diferente cantidad de variables involucradas, las detallaremos a continuación.

Hipótesis 1

Univariada:

"Más del 50% de los productos ofrecidos son de mala calidad (un nutriscore con valor D o E)"

Nos pareció relevante plantear esta hipótesis porque, como ya dijimos, el dataset proviene de un rejunte de comidas a escala global. Esto nos hace preguntarnos si los alimentos que consume la población (y consumimos nosotros mismos) del mundo son de baja calidad.
Antes de empezar, nos dimos cuenta de que iba a ser difícil trabajar con la variable nutriscore en el estado en que se encontraba, por lo que procedimos a hacer una transformación de los datos, formando la columna "es_malacalidad". La nueva columna es una variable categórica nominal dicotómica donde el valor '1' denota que el producto es de mala calidad y el '0' indica que el producto es de buena calidad.

Para verificar la hipótesis, hicimos el Test de Hipótesis para una Proporción Poblacional (Prueba Z de una Proporción):

1. Definimos el parámetro p como la proporción poblacional real de productos de mala calidad, y las hipótesis:

   Hipótesis Nula (H0): $p <= 0.50$
   Hipótesis Alternativa (H1): $p > 0.50$

   Donde H0= "Menos de la mayoría de productos es de mala calidad"
   y H1= "La mayoría de productos son de mala calidad"

2. Establecemos el intervalo de confianza del 95%, con a = 0.05. Si el p valor es menor a 0.05, podemos rechazar la hipótesis nula.

3. Como la muestra es grande y la variable es dicotómica, podemos utilizar el estadístico de prueba Z con aproximación normal:

$$Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}}$$

Donde:

- $\hat{p}$: Proporción muestral observada ($\hat{p} = \frac{x}{n}$, número de éxitos / tamaño muestral).
- p_0: Valor hipotetizado bajo la nula ($p_0 = 0.50$).
- n: Tamaño total de la muestra analizada.

4. Análisis del resultado:
    - Si p < a, se rechaza H0 y se concluye que hay evidencia estadística suficiente para afirmar que más del 50% de los productos son de mala calidad.
    - Si p >= a, no se rechaza H0.

Cuando corrimos los tests en el Jupyter Notebook, obtuvimos este output:

Tamaño muestral (n)	: 4581
Productos de mala calidad (x)	: 1919
Proporción observada ($\hat{p}$)	: 0.4189 (41.89%)
Estadístico Z de prueba	: -11.1249
p-valor (p-value)	: 1.0000

Decisión: No rechazar H0 (p-valor >= 0.05).

En conclusión, no existe evidencia suficiente para afirmar que más del 50% de los productos son de mala calidad.

Cabe aclarar que esta conclusión depende mucho de lo que el investigador considere como “buena” y “mala” calidad. Nosotros elegimos las categorías A,B y C como

buenas y D y E como malas, pero probamos incluyendo la categoría C como mala y la hipótesis alternativa se aceptaba.

Hipótesis 2

Bivariada:

"Los productos con mayor grado de procesamiento industrial (nova_group) son los que más impacto ambiental (ecoscore_grade) generan"

Nos pareció de interés plantear esta hipótesis para ver si los alimentos ultraprocesados son más dañinos para el ambiente que el resto de alimentos, si así lo fuera, podríamos tomar mejores decisiones a la hora de consumir, bajando nuestra huella de carbono.

En este caso tomamos:

H0: No hay relación entre el aumento del grado de procesamiento industrial y el aumento del impacto ambiental.

H1: Hay relación entre el aumento del grado de procesamiento industrial y el aumento del impacto ambiental.

Como ambas variables son cualitativas ordinales, decidimos utilizar el test no paramétrico de la correlación de Spearman, que mide la fuerza y el sentido de la relación (si al aumentar nova_group tiende a empeorar el ecoscore_grade).

Primero hicimos un heatmap para ver la distribución de valores entre ambas variables:

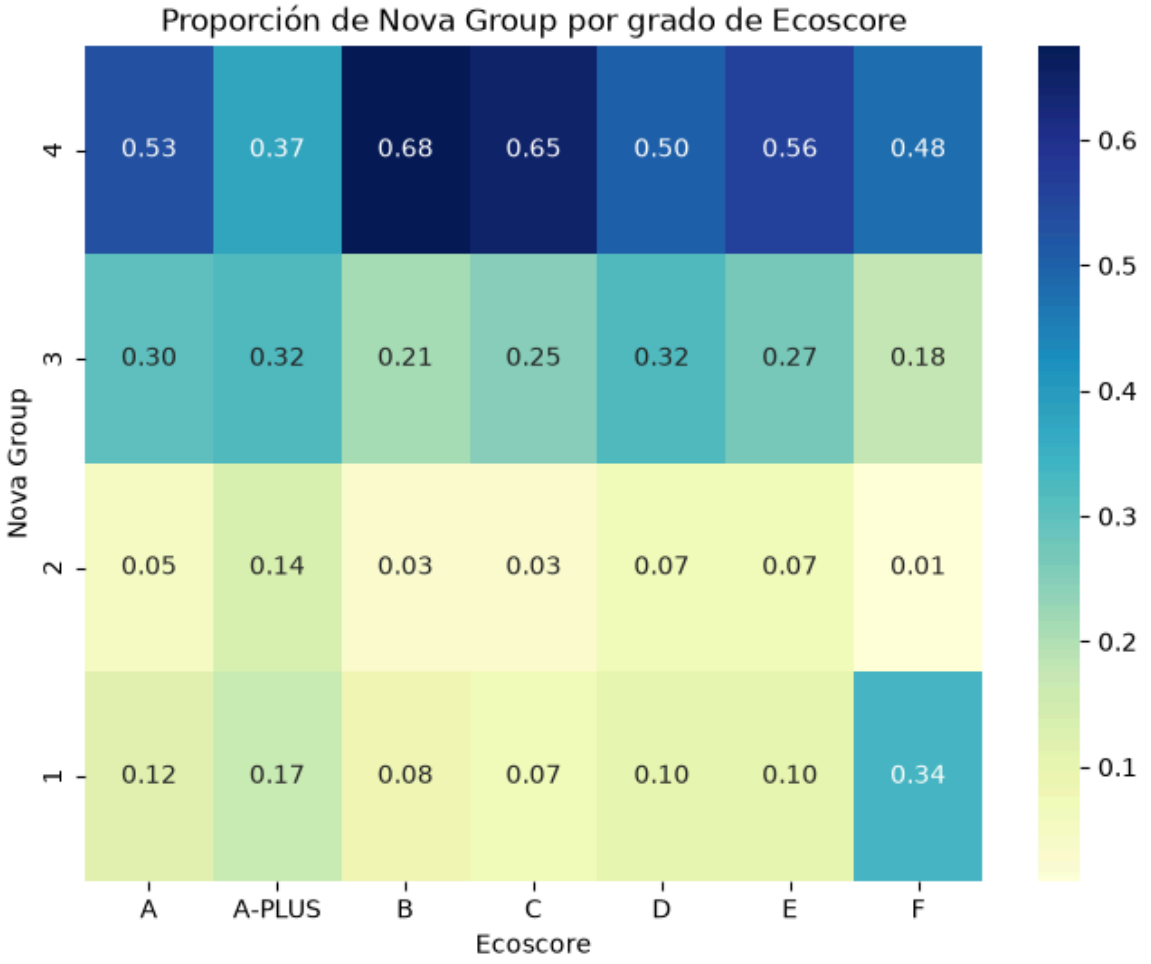


fig 6: Heatmap para representar la frecuencia de aparición conjunta entre los valores de nova group y ecoscore.

A simple vista, se puede ver una relación muy ligera entre el aumento del impacto ambiental con el aumento del procesamiento industrial, ya que vemos una leve concentración de valores en la esquina superior derecha.

Para demostrar definitivamente esta hipótesis, debemos elegir un test que funcione en muestras no apareadas (ya que no consideramos que haya una dependencia entre los valores del ecoscore con el nova group). Al ser variables de pocas categorías y ordinales, utilizaremos el test no paramétrico de Spearman, que mide la fuerza y el sentido de la relación (si al aumentar nova_group tiende a aumentar el ecoscore_grade). Luego de ejecutar el test en nuestro notebook de jupyter, el output que obtuvimos es el siguiente:

Coeficiente de correlación de Spearman: -0.0045

p-valor: 0.7583508129060519

Podemos concluir entonces que, como el p-valor es mayor a nuestro alfa (0.05), no se puede rechazar la hipótesis nula (H0). No hay evidencia estadística de que el nivel de procesamiento afecte al impacto ambiental en esta muestra.

Hipótesis 3

Multivariada

"Los productos con mayor cantidad de grasas saturadas, azúcares y calorías tienen mayor grado de procesamiento industrial. "

Al plantear esta hipótesis, quisimos analizar si el valor nutricional de un alimento (específicamente, su cantidad de azúcares, calorías y grasas saturadas) puede determinar si tiene un alto grado de procesamiento, ya que los alimentos ultraprocesados pueden llevar a enfermedades como la diabetes de tipo 2, obesidad, enfermedades cardiovasculares, entre otras. Analizar esta hipótesis nos ayudará a tomar decisiones informadas sobre los alimentos que consumimos.
Donde las hipótesis nulas y alternativas se definen de la siguiente manera:

> H0: La cantidad de grasas saturadas, azúcares y calorías no influyen lo suficiente en el grado de procesamiento industrial como para poder explicar su comportamiento.
>
> H1: La cantidad de grasas saturadas, azúcares y calorías influyen lo suficiente en el grado de procesamiento industrial como para poder explicar su comportamiento.

Para trabajar esta hipótesis tuvimos que hacer una regresión logística porque nuestra variable dependiente (nova_group) es categórica. Al no ser binaria, hicimos una columna binaria llamada "nova_alto" donde un valor "1" indica que el valor de nova es 3 o 4, siendo el valor "0" representativo de un valor NOVA igual a 1 o 2.

Al haber aproximadamente un 15% de valores nulos, decidimos probar modelos con distintos tratamientos de nans: en el primero imputamos por la mediana las variables independientes, y por la moda en el caso de nova_group; en el segundo caso eliminamos todas las muestras con valor nulo en alguna de las columnas del modelo; y por último, imputamos por la técnica KNN. En ambas técnicas de imputación se analizó la distribución antes y después de los datos, para asegurarnos que no haya cambiado de forma significativa.

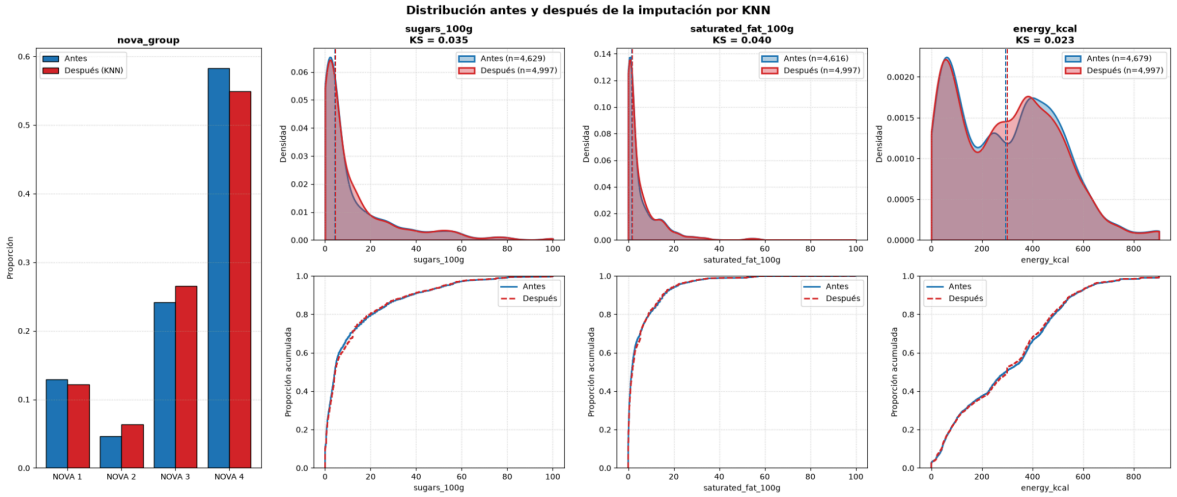


fig 7: Conjunto de gráficos para representar y comparar las distribuciones de las variables nova_group, sugars_100g, saturated_fat_100g y energy_kal antes y después de la imputación por k vecinos más cercanos.

Probamos estos tres casos con el objetivo de observar cómo van cambiando los modelos con las distintas técnicas, en qué casos resulta un mejor o peor modelo, y en qué casos se mantienen igual. En los tres casos los modelos tuvieron un valor bajo del Pseudo-R^2 de McFadden, el cual evalúa qué tan exactas son las probabilidades estimadas, respecto a un modelo sin variables. También tuvieron valores bajos de AUC, que representa la capacidad del modelo de discriminar entre los dos posibles valores que puede tomar nova_alto:

- Caso 1: McFadden: 0.011, AUC: 0.608.

- Caso 2: McFadden: 0.016, AUC: 0.625.
- Caso 3: McFadden: 0.011, AUC: 0.604.

Podemos ver que hubo una pequeña mejora en el caso donde eliminamos los nulos, pero es mínima. Que el valor de AUC esté entre 0.6 y 0.7 significa que las variables independientes tienen capacidad predictiva, pero es débil. Viéndolo en conjunto con los valores de Pseudo-R^2, al ser en los tres modelos cercanos a cero, podemos decir que las variables elegidas explican poco sobre el grado de procesamiento de un producto.

De todas formas, en los tres modelos las variables *azúcares en 100g* y *grasas saturadas en 100g* dieron que son significativas para la predicción del grado nova (ya que su p-valor es menor a nuestro alpha 0.05), por lo tanto confirmamos que sí están relacionadas estas variables. Sin embargo, sólo los azúcares se relacionan de forma positiva (con un coeficiente de 0.16 a 0.32, según el modelo) como habíamos planteado en la hipótesis, mientras que las grasas saturadas actúan de forma inversa (coef. 0.23 a 0.28) a la pensada: tienen relación negativa, lo que implica que a medida que aumentan las grasas saturadas de un alimento, tiende a bajar el grado de procesamiento del mismo. En el contexto real del problema, esto tiene sentido, ya que alimentos altísimos en grasas saturadas como quesos, manteca y crema son de grado nova 2 (bajo), mientras que muchos ultraprocesados como gaseosas, cereales y snacks tienen poca cantidad de grasas saturadas.

Con respecto a las calorías de un alimento, sólo dió como significativo en el último modelo, por lo que decidimos no tenerlo en cuenta para la conclusión final.

En conclusión, sólo se cumplió parcialmente nuestra hipótesis: pudimos corroborar que a mayor cantidad de azúcares, mayor grado de procesamiento. De todas formas, esta única variable es suficiente para rechazar la hipótesis nula, y asegurar que existe una relación entre los azúcares, grasas saturadas, y grado de procesamiento.

Cuarto paso: Comprobación de hipótesis dadas

Como cuarta consigna, tuvimos que validar ciertas hipótesis suministradas por la cátedra. En total eran 3, una univariada, una bivariada y una multivariada. Nuestro desarrollo se muestra a continuación:

Hipótesis 4

Univariada

"La proporción de productos catalogados como "altos en grasas saturadas" (más de 5 g de grasa saturada por cada 100 g de producto) en la población de referencia es superior al 25%."

Estudiar esta hipótesis nos permite saber en qué magnitud de alimentos a los que estamos expuestos las grasas saturadas son altas, y es de interés ya que el exceso de grasa saturada se asocia con enfermedades cardiovasculares y colesterol alto, los cuales son dañinos a la salud. Saber esto nos permite tomar decisiones para mejorar el valor nutricional de los alimentos.
Donde H0: $\hat{p} <= 0.25$ (la proporción de productos catalogados como "altos en grasas saturadas" en la población de referencia es menor o igual al 25%)
y H1: $\hat{p} > 0.25$(la proporción de productos catalogados como "altos en grasas saturadas" en la población de referencia es mayor al 25%).

Para corroborar la hipótesis planteada, utilizamos el test de hipótesis para una proporción poblacional (Prueba Z de una proporción), que es el mismo procedimiento que utilizamos para el primer inciso del paso anterior.
El output que obtuvimos de hacer la prueba es el siguiente:

=== RESULTADOS DEL TEST DE HIPÓTESIS ===

Tamaño muestral (n)	: 4997
Productos altos en grasas saturadas	: 1632
Proporción observada ($\hat{p}$)	: 0.3266 (32.66%)
Estadístico Z de prueba	: 11.5456

p-valor (p-value) : 0.0000

Decisión: Rechazar H0 (p-valor < 0.05).
En conclusión, existe evidencia suficiente para afirmar que más del 25% de los productos son altos en grasas saturadas.

Hipótesis 5

Bivariada

"El grado de procesamiento industrial de un alimento está asociado con la calificación nutricional Nutri-Score que recibe, de manera que los productos más procesados presentan calificaciones más desfavorables."

Analizar esta hipótesis nos permitirá saber si al conocer que un alimento es procesado o ultra procesado, podemos estimar si su valor nutricional es desfavorable o favorable. También nos permitirá tomar mejores decisiones acerca de los alimentos que consumimos.
En este caso establecimos las hipótesis nula y alternativa de la siguiente manera:

> H0: no hay relación estadísticamente significativa entre la calificación nutricional nutri-score y el grado de procesamiento industrial
>
> H1: hay una relación estadísticamente significativa entre la calificación nutricional nutri-score y el grado de procesamiento industrial

El valor de esta hipótesis está en ver si podemos explicar que los productos con una calificación nutricional baja son una consecuencia de un alto grado de procesamiento industrial, y generar conciencia sobre la calidad de este tipo de productos que son tan comunes hoy en día.
Las variables que tuvimos que limpiar para comprobar esta hipótesis fueron Nutri-Score y Nova Group. Como ambas variables contienen nulos, vamos a imputar

estos valores usando el algoritmo k-NN. Para poder poder imputar por vecinos más cercanos tuvimos que analizar qué tipo de vecinos queríamos que aportaran información. Concluimos que los vecinos que aportasen no deberían tener muchos nulos, sobre todo teniendo en cuenta de que necesitamos columnas numéricas para poder imputar. A continuación se muestran gráficos que muestran cuántos nulos hay en la fila cuando Nova Group y Nutri-Score son nulos, respectivamente:

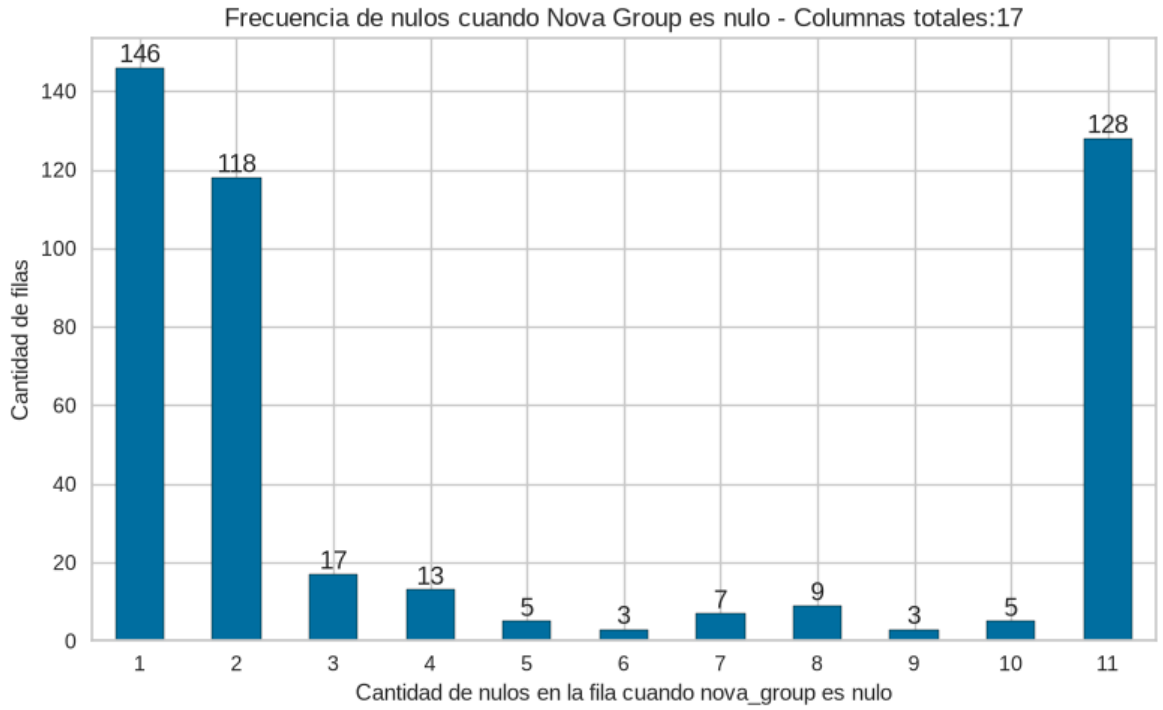


fig 8: Este gráfico de barras muestra cuántos nulos hay en las filas donde nova_group es nulo.

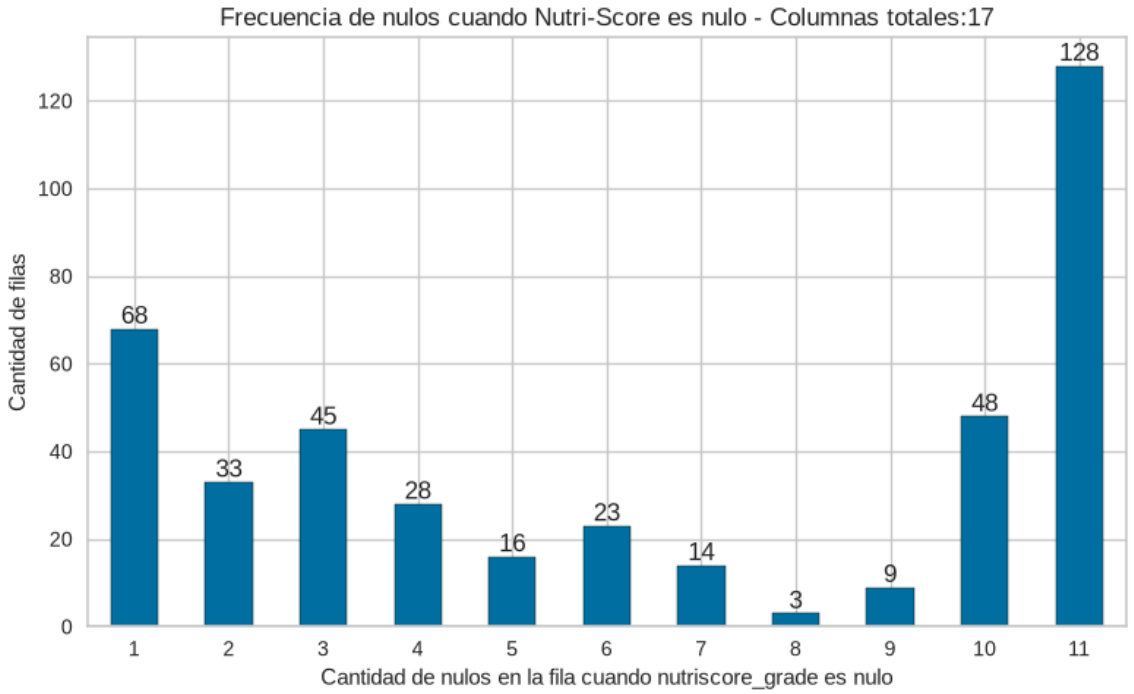


fig 9: Este gráfico de barras muestra cuántos nulos hay en las filas donde nutri-score es nulo.

Vemos que aparecen muchos nulos, por lo que para este análisis vamos a eliminar aquellas filas que tengan más de 5 nulos. Además, nos pareció que al estar calculando una correlación entre variables, al menos una de estas debe ser un valor original, por lo que borramos aquellas filas donde ambas variables eran nulas. Tras este borrado, graficamos de nuevo la cantidad de nulos cuando alguna variable objetivo es nula:

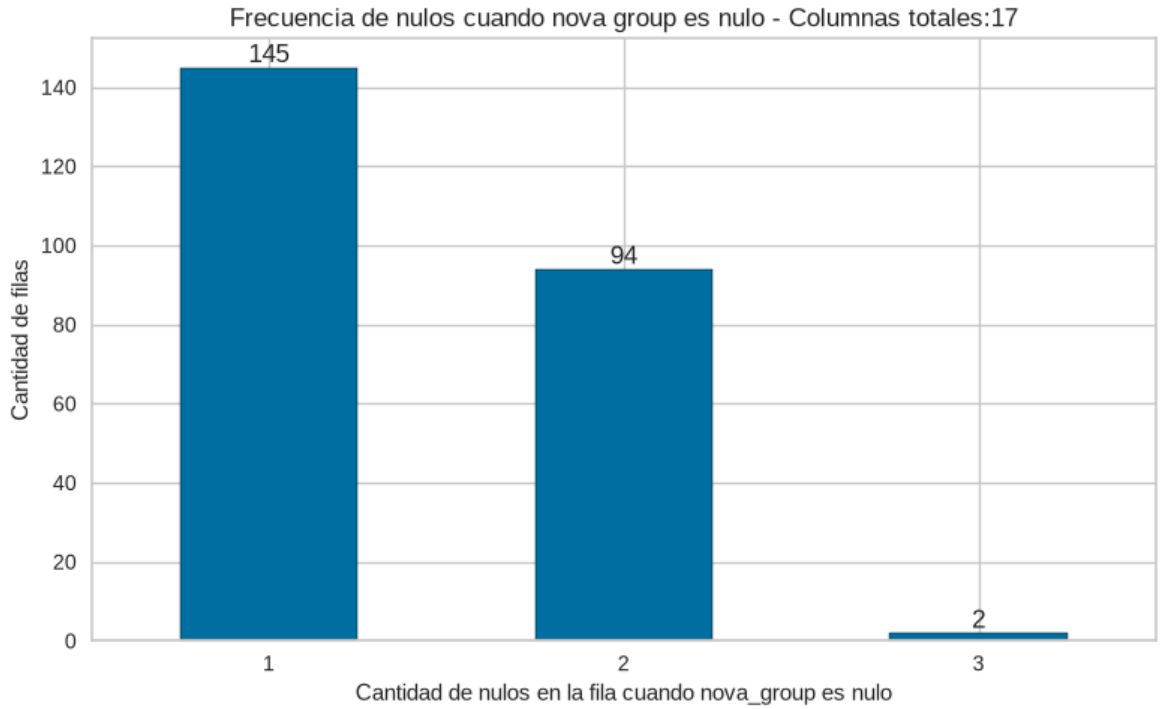


fig 10: Este gráfico de barras representa la cantidad de nulos en las filas cuando nova_group es nulo, pero después de descartar las filas que tenían más de 5 nulos y las dos variables objetivo nulas.

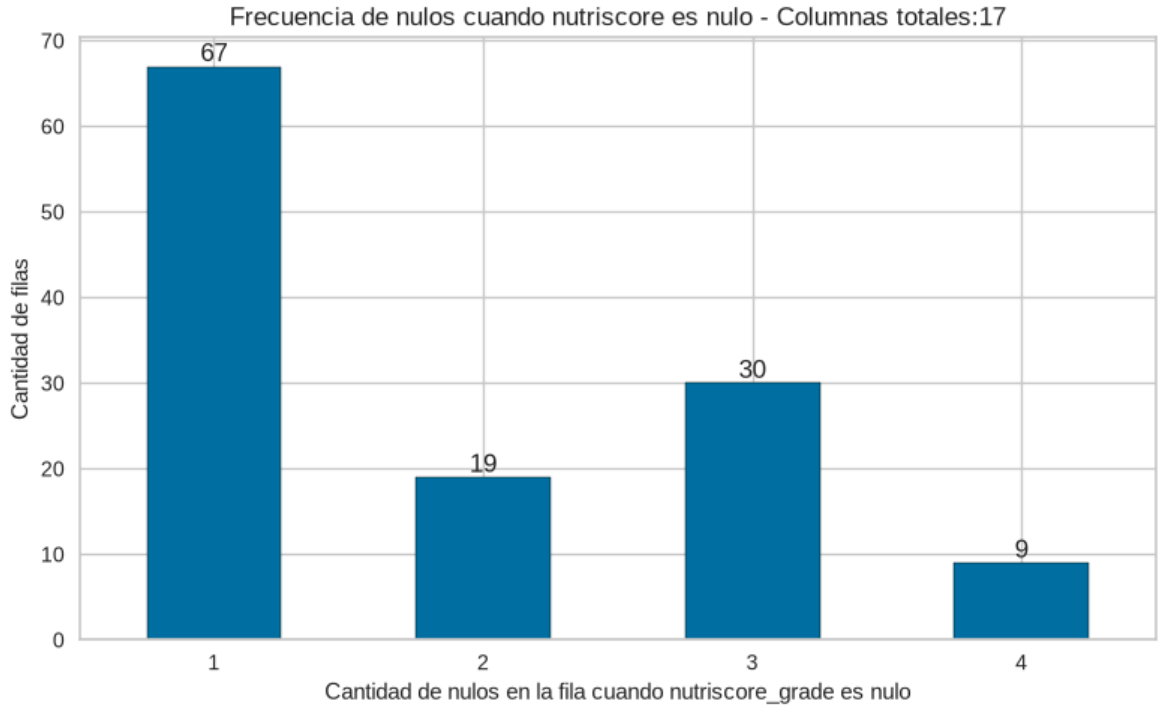


fig 11: Este gráfico de barras representa la cantidad de nulos en las filas cuando nutriscore_grade es nulo, pero después de descartar las filas que tenían más de 5 nulos y las dos variables objetivo nulas.

Ahora si, con filas con pocos nulos podemos proceder a hacer la imputación. Como estamos tratando con columnas categóricas ordinales y la imputación toma el promedio de las k filas más cercanas, esto resulta en valores con coma, cuando originalmente teníamos valores enteros. Entonces para los valores imputados, les vamos a asignar el valor más cercano que tengan, por ejemplo si se imputó un Nova Group de 2.1, le asignamos un 2.

Para elegir el valor de k, nos basamos inicialmente en una regla general que dice que el k debe ser la raíz cuadrada de la cantidad de muestras, que para nuestro dataset este valor nos daba 70. Tras aplicar el algoritmo muchas filas caían en un mismo valor, tanto en Nutri-Score como en Nova Group, por lo que probamos valores más bajos (entre 3 y 7) y valores intermedios (entre 15 y 40). Finalmente nos quedamos con k=30 que fue el que hizo imputaciones más coherentes. Este análisis no lo hicimos viendo los valores a secas, sino gráficamente, mostrando en un gráfico de barras frecuencias originales de las variables junto a las frecuencias con las nuevas variables imputadas. Lo que buscábamos es que las distribuciones sean similares, que no se haya imputado demasiado o muy poco por un valor. Los siguientes gráficos muestran esa comparación para k=30.

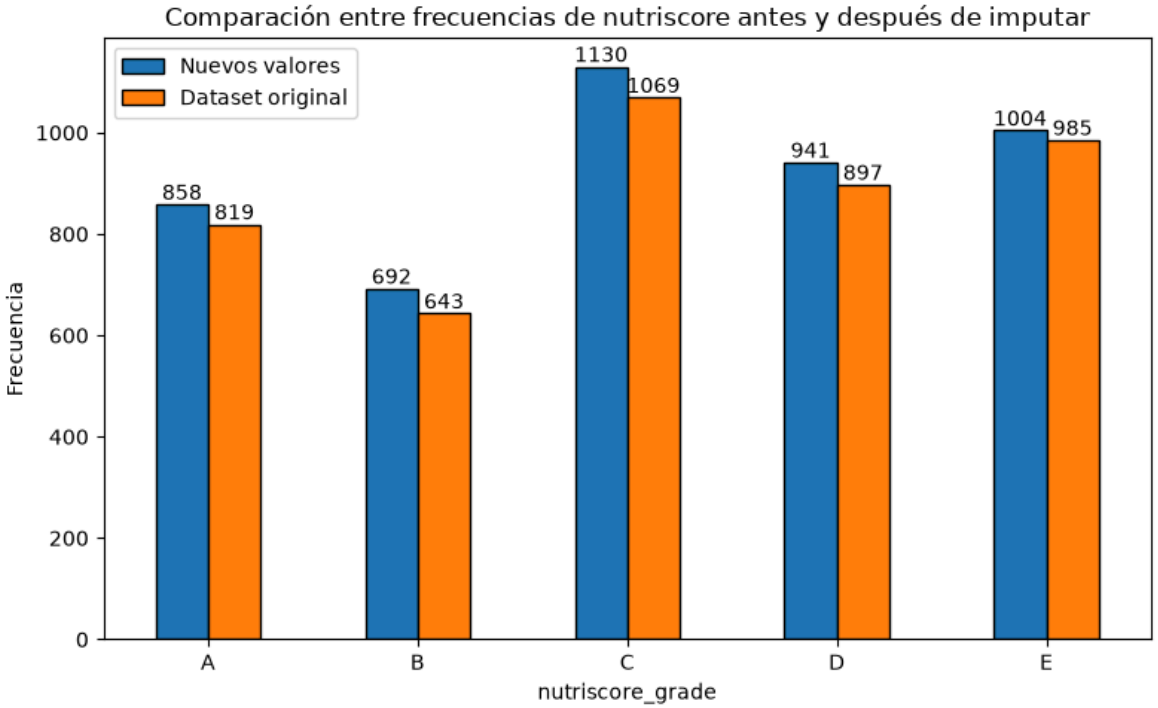


fig 12: Gráfico comparativo entre las frecuencias de los distintos valores que puede tomar nutriscore_grade antes y después de imputar

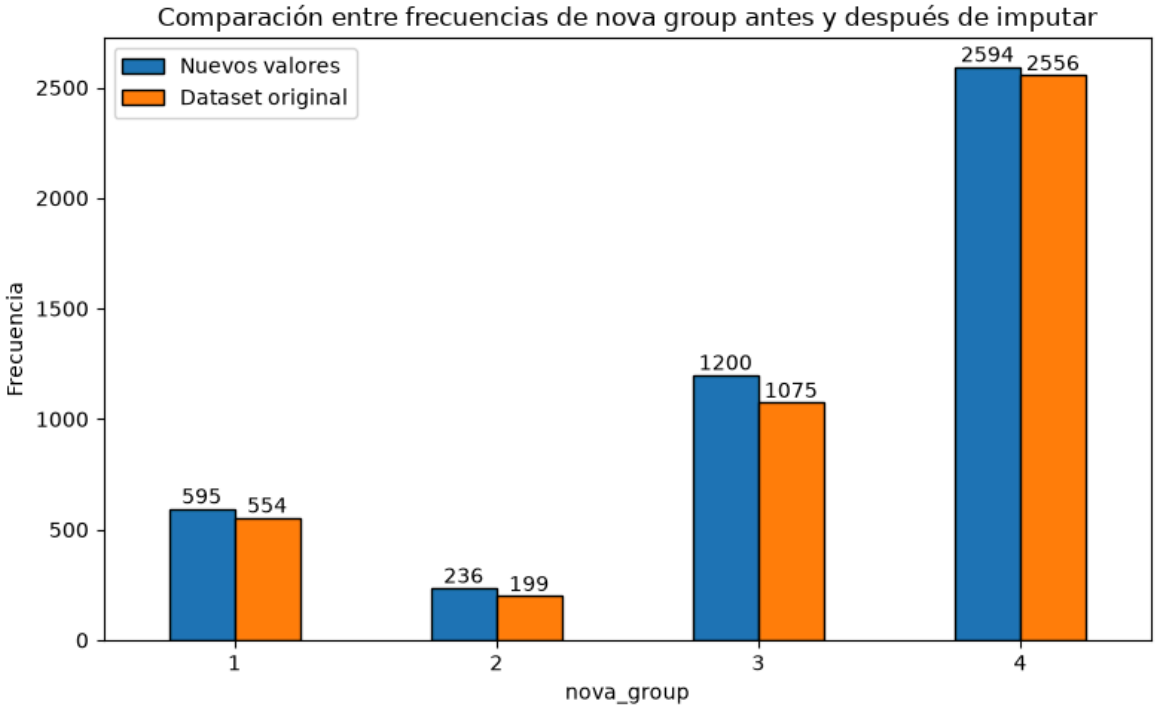


fig 13: Gráfico comparativo entre las frecuencias de los distintos valores que puede tomar nova_group antes y después de imputar

Vemos que los valores imputados son razonables y no parecen haber valores con muchas o pocas imputaciones. Por lo que ahora que tenemos los datos limpios, vamos a pasar a comprobar si existe la correlación.

Para hacer un análisis inicial, hicimos un heatmap, el cual tiene en cada celda el porcentaje de muestras con ese valor de Nova Group, dado el valor de Nutri-Score.

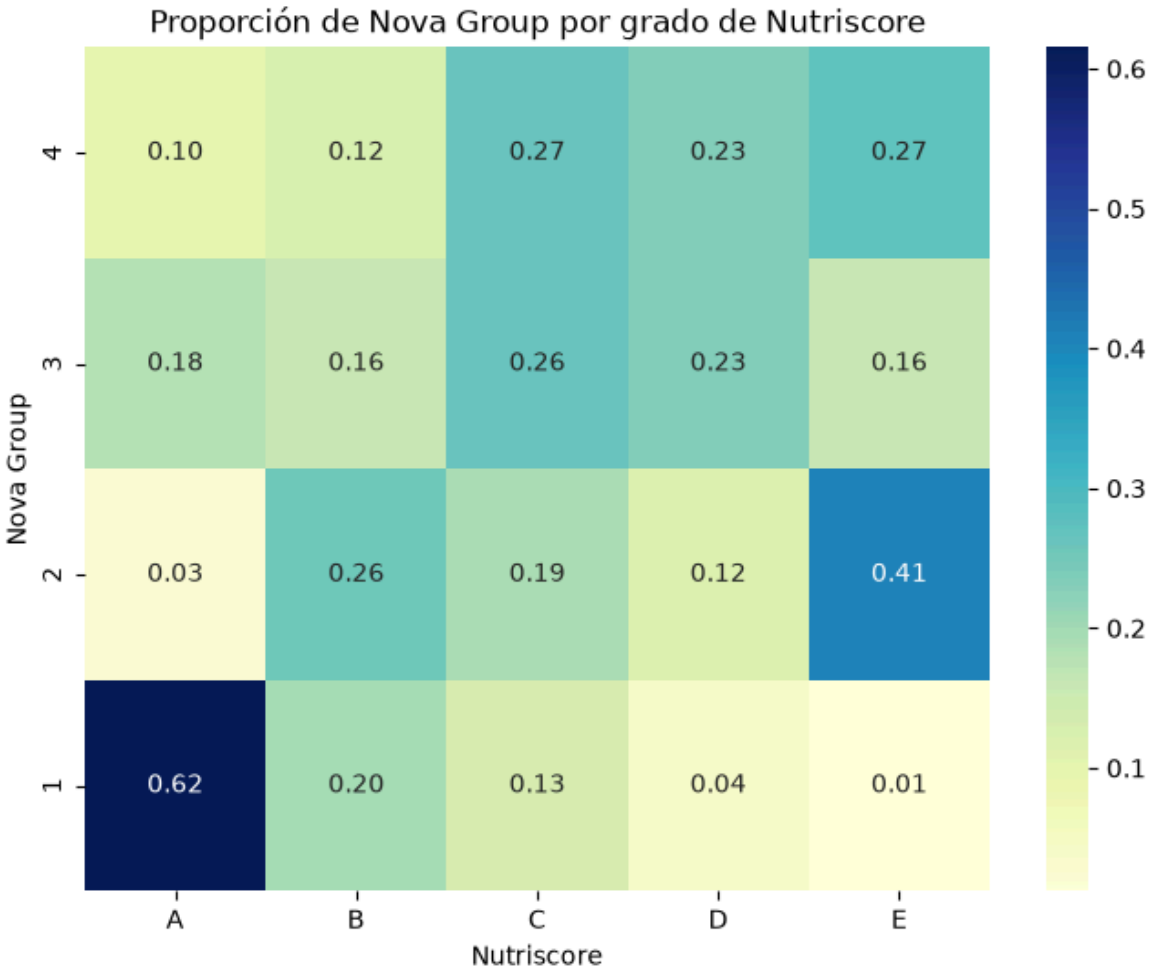


fig 14: Heatmap para representar la frecuencia de aparición conjunta entre los valores de nova_group y Nutriscore_grade

Viendo el gráfico se puede observar una tendencia a los valores de la diagonal. Es llamativa la celda más oscura, cuando el Nutri-Score es A, en la mayoría de muestras el Nova Group es 1. Esto parece favorecer la hipótesis. Por otro lado, vemos que para Nutri-Score E es frecuente que el Nova Group sea 2. No esperábamos que para Nutri-Score E sea tan frecuente un Nova Group de 2.

Para corroborar de manera definitiva la hipótesis, realizamos un test de correlación de Spearman, el resultado obtenido fue el siguiente:

Coeficiente de correlación de spearman: 0.3220

p-valor: 4.901170459812916e-112

Si bien existe una correlación positiva entre ambas variables, el coeficiente de correlación es de 0.322, lo cual no nos indica una correlación fuerte entre las variables. De todas formas, el p-valor al ser cercano a cero nos permite rechazar la hipótesis nula y concluir que sí hay una relación estadísticamente significativa entre el grado de procesamiento industrial y el valor nutri-score del alimento.

Hipótesis 6

Multivariada

"El grado de procesamiento industrial (NOVA), la categoría del producto y la cantidad de alérgenos declarados explican conjuntamente la probabilidad de que un producto reciba una calificación Nutri-Score desfavorable (D/E), sin utilizar directamente su composición nutricional."

Primero dejamos establecidas de manera clara las hipótesis nula y alternativa:

> H0: El grado de procesamiento industrial (NOVA), la categoría del producto y la cantidad de alérgenos no pueden explicar la probabilidad de que un producto reciba una calificación Nutri-Score desfavorable, sin utilizar directamente su composición nutricional.
>
> H1: El grado de procesamiento industrial (NOVA), la categoría del producto y la cantidad de alérgenos pueden explicar la probabilidad de que un producto reciba una calificación Nutri-Score desfavorable, sin utilizar directamente su composición nutricional.

Esta hipótesis nos va a permitir entender qué tipo de productos tienen un bajo valor nutricional sin ver directamente sus valores nutricionales, lo cual es valioso para comprender qué tipo de productos son nutritivos o no únicamente viendo algo que se ve a simple vista, como por ejemplo la categoría del producto o el grado de procesamiento.

A la hora de hacer la preparación para esta hipótesis, nos encontramos que la mayor dificultad iba a ser cómo íbamos a representar las categorías de cada producto,

siendo que es una variable categórica nominal, la cual tiene 360 valores distintos. Lo primero que hicimos fue listar cada una de las categorías junto a la cantidad de apariciones que tenían en el dataset, y pudimos observar que las categorías más frecuentes tenían entre 2000 y 300 apariciones. Gran parte de las categorías contaban con menos de 20 representaciones, que tras observarlas en detalle nos dimos cuenta de que la mayoría eran categorías específicas las cuales tenían un representante más general. Por ejemplo, hay 12 productos que se catalogaron como leches homogeneizadas, mientras que 753 productos fueron catalogados como lácteos. Entonces en este punto decidimos que solo íbamos a conservar las categorías con más apariciones y las transformaremos en columnas, las cuales tendrán un booleano indicando si el producto fue catalogado o no con dicha categoría. Luego, tuvimos que inspeccionar dichas categorías, y eliminamos categorías que tenían redundancia con otras:

- "Comidas y bebidas basadas en plantas" y "Comidas basadas en plantas"
  Todos los productos con "Comidas basadas en plantas" también fueron catalogados como "Comidas y bebidas basadas en plantas", por lo que "Comidas basadas en plantas" que es una categoría menos abarcativa, la eliminamos.

- "Bebidas", "Bebidas y preparaciones de bebidas" y "Preparaciones de bebida"
  Preparaciones de bebidas refiere a productos como café, cacao en polvo, entre otros similares. Cuando el producto no tenía la categoría "Bebidas" pero sí alguna de las otras dos, la categoría "Preparaciones de bebida" era válida. Entonces lo que hicimos fue que si no estaba en bebida pero si en alguna de las otras, lo dejamos como "Preparaciones de bebida", mientras que la categoría "Bebidas y preparaciones de bebida" la eliminamos porque era redundante.

- "Lácteos", "Fermentados" y "Lácteos fermentados"
  Los productos que sean "Lácteos fermentados", pueden estar correctamente catalogados usando las primeras categorías, por lo que a esta última la

eliminamos.

- “Snacks”, “Snacks dulces” y “Galletitas y tortas”
  El comportamiento que observamos con estas categorías fue que todos los productos catalogados como “Galletitas y tortas” también lo están como “Snacks dulces”. Por otro lado, los productos catalogados como “Snacks dulces” siempre lo están como “Snacks”. Reducir todo a “Snack” hubiese sido descartar demasiada información, ya que hay 1041 snacks, de los cuales 737 son snacks dulces. Pero la categoría “Galletitas y tortas” la podemos eliminar ya que estos productos ya están catalogados como “Snacks dulces”, así eliminamos la redundancia y disminuimos la cantidad de columnas.

- “Salsas” y “Condimentos”
  Todas las salsas también están catalogadas como condimentos, por lo que decidimos borrar la categoría salsa ya que está representada por condimento y reducimos la cantidad de columnas.

Tras hacer esta limpieza, de 4997 productos, 4438 tienen alguna de las 9 categorías con más apariciones. Respecto a los productos restantes, a fin de evitar que estos tengan falso en todas las nuevas columnas, decidimos crear una columna “Otros” que es verdadera cuando el producto no fue catalogado con ninguna de las categorías principales.
Respecto a la cantidad de alérgenos, lo que hicimos fue tomar la variable “cant_allergens” que lista textualmente los alérgenos, contabilizarlos y dejarlos en una nueva columna.
A la hora de tratar las variables de los valores nulos de Nutri-Score y Nova Group, se hizo una imputación por k-NN usando k=10, que fue el valor que nos dio una distribución similar a la original. En la hipótesis 5 se explica con mejor detalle cómo se realizó dicha imputación, ya que el procedimiento fue el mismo. Además, para la variable objetivo que es Nutri-Score, como la hipótesis nos pregunta si podemos predecir si un producto obtiene un valor desfavorable para esta variable, lo que

hicimos fue crear una nueva columna booleana que tiene 1 si el Nutri-Score es D o E, y 0 para los otros casos.

Con las variables ya limpias, podemos pasar a la comprobación de la hipótesis. Para ello decidimos entrenar un modelo de regresión logística, el cual usando las categorías, la cantidad de alérgenos declarados y el valor Nova Group del producto, intentará predecir si el Nutri-Score del mismo es favorable o desfavorable. El primer paso fue separar el dataset en un conjunto de entrenamiento y un conjunto de prueba:

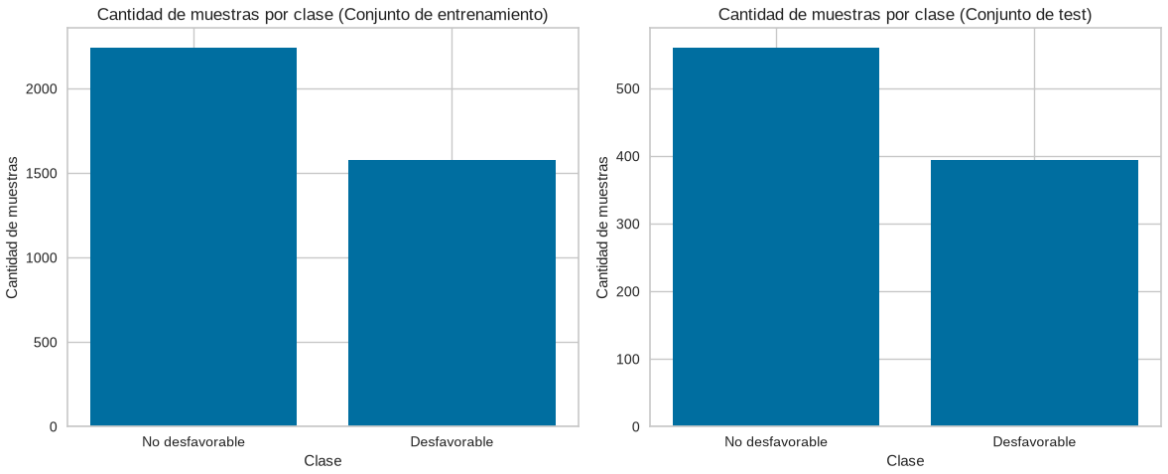


fig 15: gráfico de barra que muestra la separación y permite corroborar la proporción de datos en el conjunto de datos destinado al entrenamiento del modelo y el conjunto destinado al testeo del modelo.

Vemos que hay una cantidad similar de Productos con Nutri-Score favorable y no favorable en ambos conjuntos, por lo que el siguiente paso fue ver como performa el modelo con y sin regularizador. Para ello usamos un grid search con valores de alpha predefinidos y penalización por “L2”. El resultado con mayor exactitud no pudo superar a la del modelo sin regularizador (73,2% contra 73,3%), que si bien la mejora es mínima, decidimos quedarnos con este. El resultado es un modelo que tiene los siguientes pesos:

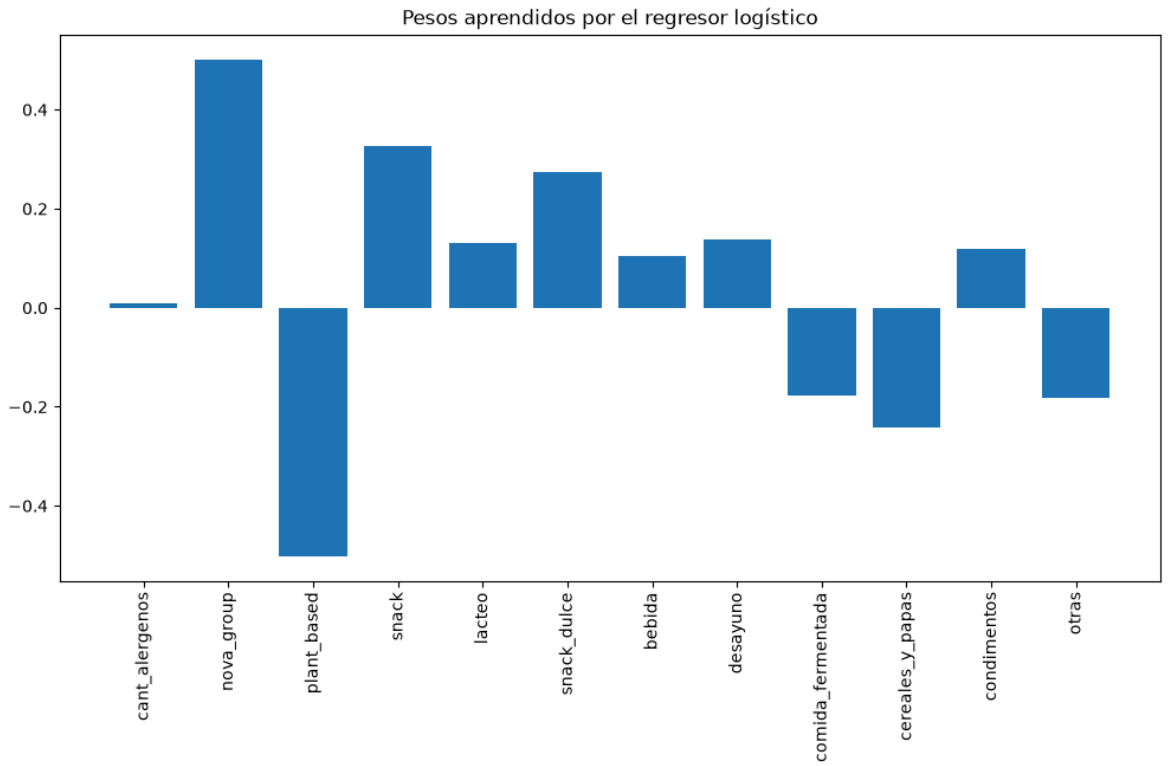


fig 16: gráfico ilustrativo de los coeficientes que el modelo aprendió para poder predecir la variable objetivo.

Se puede observar que un nivel de procesamiento alto, ser catalogado como snack o snack dulce contribuyen más a la probabilidad de un producto con Nutri-Score desfavorable, mientras que sólo cuatro variables contribuyen a un Nutri-Score no desfavorable, que son "Productos basados en plantas", que es la que más pesa, "Comidas fermentadas", "Cereales y papas" y "Otros". Por otro lado vemos que la cantidad de alérgenos tiene un valor muy cercano a 0 por lo cual no es muy significativa para el modelo.

Finalmente vamos a testear el modelo y ver qué tan bien predice usando el conjunto de datos de test. El resultado de ese testeo es la siguiente matriz de confusión:

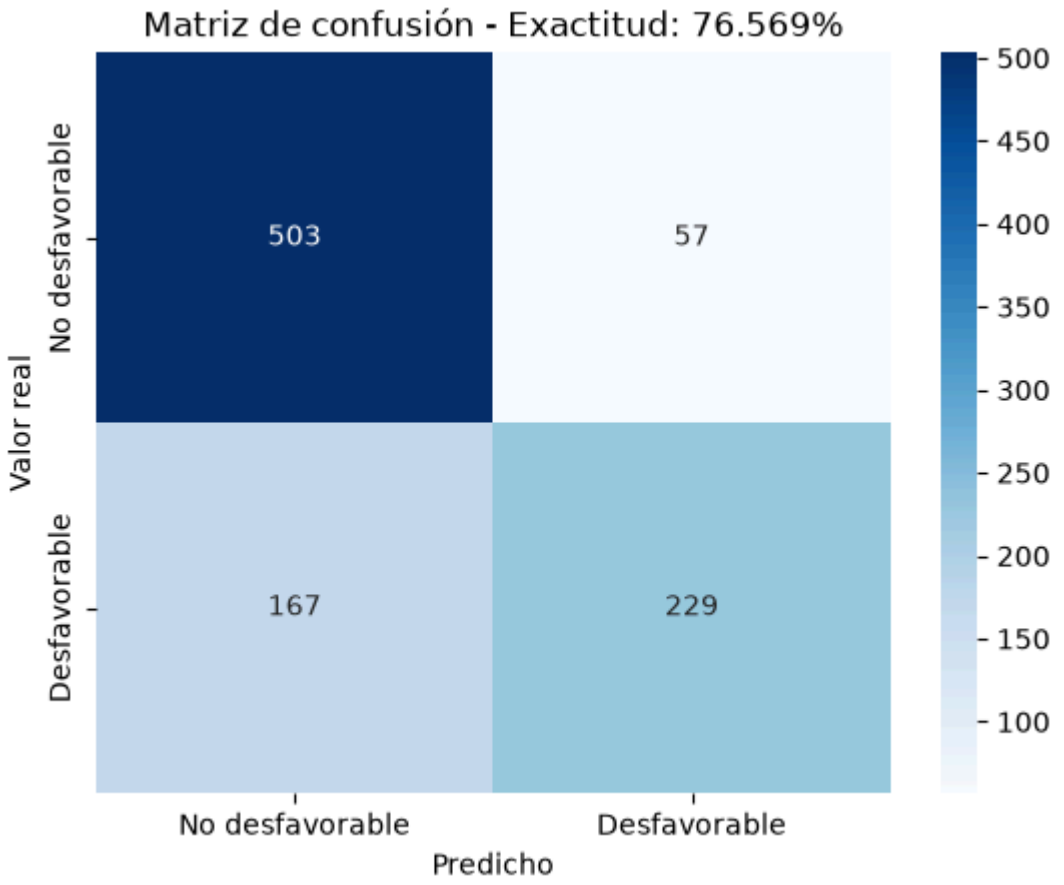


fig 17: matriz de confusión resultado de utilizar el conjunto de datos destinado al testeo en el modelo

Viendo la matriz de confusión podemos decir que los valores de la diagonal son los más frecuentes. Analizando la exactitud del modelo según el tipo de entrada, vemos que para productos con Nutri-Score favorable, el modelo suele acertar bastante (~89%), mientras que cuando el producto tiene Nutri-Score desfavorable, el modelo erra bastante, consiguiendo acertar solo en el ~59% de los casos. Ahora analizando la salida del modelo, cuando obtenemos que el producto tiene Nutri-Score favorable, la probabilidad de que verdaderamente tenga Nutri-Score favorable es del 75%. Por otro lado, cuando se predice Nutri-Score desfavorable las probabilidades de que haya habido un acierto son aproximadamente del 80%.

Finalmente, si bien el modelo tiende a equivocarse más cuando la entrada es un producto con Nutri-Score desfavorable, podemos concluir que las categorías del

producto, la cantidad de alérgenos y el grado de procesamiento industrial explican en gran medida la probabilidad de que un producto tenga Nutri-Score desfavorable.

Conclusiones generales:

A lo largo del desarrollo de este trabajo aprendimos a seguir una metodología de trabajo concreta y a ajustar los datos de manera que estos fuesen útiles y significativos para el análisis que queríamos hacer.

Con respecto a las hipótesis planteadas por el grupo pudimos llegar a varias conclusiones. En primer lugar, no pudimos afirmar que la mayoría de productos (más del 50%) del dataset son de mala calidad así como tampoco pudimos encontrar una correlación significativa entre el nivel de procesamiento industrial y el impacto ambiental de un producto. Sin embargo, si pudimos concluir que existe una relación entre los azúcares, grasas saturadas, y grado de procesamiento y que éstos valores si ofrecen información que puede ayudar a explicar el comportamiento de la variable nova_group.

En cuanto a las hipótesis planteadas por la cátedra, pudimos encontrar evidencia estadísticamente significativa de que más del 25% de productos del dataset son altos en grasas saturadas pero no corrimos con la misma suerte a la hora de determinar si hay una relación estadísticamente significativa entre el grado de procesamiento industrial y el valor nutri-score del alimento, llegando a la conclusión de que no existe tal relación. Por último, a la hora de evaluar la hipótesis multivariada, pudimos concluir que las categorías del producto, la cantidad de alérgenos y el grado de procesamiento industrial explican en gran medida la probabilidad de que un producto tenga Nutri-Score desfavorable.

Para concluir, reflexionamos sobre la industria alimentaria y concluimos que los datos disponibles son muchos y muy variados, por lo que la puerta está abierta para nuevas investigaciones y reflexiones, quizás sobre la industria a nivel nacional o regional. Agradecemos la oportunidad a la cátedra de trabajar con datos e instrumentos reales para poder seguir formándonos como profesionales.

Bibliografía y enlaces de interés:

https://www.kaggle.com/datasets/ahsanneural/global-food-and-nutrition-database-2026/data - SItio desde el cual asumimos que salió el dataset